

תזמור סוכני בינה מלאכותית: מ-Prompting ל-Crews מוכנים לייצור

ארכיטקטורה, תזמור, והפקת מסמכים דטרמיניסטית

Amr Safadi and Sharbel Maroun

AI Agent Orchestration
מרצה: Dr. Yoram Segal

04-06-2026

תוכן העניינים

1	מ-Prompts למערכות סוכנים (From Prompts to Agent Systems)	3
1.1	2026 כנקודת מפנה: מ-helper לשכבה תפעולית	3
1.2	מדוע prompt בודד וארוך נכשל	3
1.3	תזת הספר: פירוק לצעדים תחומים, ניתנים לבדיקה ולשליטה	4
1.4	איורים, טבלה ונוסחה	4
1.5	מעבר דו-כיווני בין עברית לאנגלית	4
2	אבני הבניין של CrewAI	7
2.1	Agent: עובד דיגיטלי בעל תפקיד	7
2.2	Task: יחידת עבודה מדידה	7
2.3	Crew, Process ו-Context: הרכבה ודבק	8
3	תזמור סדרתי הלכה למעשה (Sequential Orchestration in Practice)	9
3.1	מדוע Sequential Process מתאים להפקת מסמכים	9
3.2	חמשת ה-Agents המתמחים ותפקידיהם	9
3.3	העברת artifacts מובנים כ-Context לאורך השרשרת	10
4	The Deterministic Harness — תשתית דטרמיניסטית סביב הסקת המודל	11
4.1	מהו Harness ולמה הוא דטרמיניסטי	11
4.2	ציטוטים, graph ו-validation כרכיבים דטרמיניסטיים	11
4.3	דטרמיניזם, reproducibility ופלט אמין	12
5	הפקת מסמכים מקצועיים באמצעות LaTeX	13
5.1	מ-artifacts מאומתים ל-LaTeX: templates ו-escaping	13
5.2	כתיבה דו-כיוונית עברית-אנגלית עם מנוע Unicode	13
5.3	ביבליוגרפיה וקומפילציה רב-מעברית של citations	14
6	מהוכחת היתכנות לסביבת Production	15
6.1	הפער השקט בין Demo ל-Production	15
6.2	אבטחת Agents ומודעות לעלות	15

6.3 מחסנית מודולרית והכיוון הבא 16

פרק 1

מ-Prompts למערכות סוכנים (From) (Prompts to Agent Systems)

1.1 2026 נקודת מפנה: מ-helper לשכבה תפעולית

במשך שנים נתפסו מודלי שפה ככלי עזר (helper) המסייע למשתמש האנושי לנסח טקסט, לסכם מסמך או להציע קטע קוד, כאשר האדם נשאר תמיד הגורם המבצע את הפעולה בפועל. שנת 2026 מסמנת נקודת מפנה (inflection point) משום שה-Agent חדל להיות נספח לממשק והופך לשכבה תפעולית (operational layer) בתוך אפליקציות ארגוניות. במקום שאדם יקרא תשובה ויעתיק אותה ידנית, ה-Agent קורא נתונים ממערכות פנימיות, מפעיל tools, כותב לבסיסי נתונים ומריץ תהליכים עסקיים מקצה לקצה. השינוי אינו טכנולוגי בלבד אלא ארכיטקטוני: ה-Agent ממוקם בנתיב הקריטי של זרימת העבודה, ולכן נדרשת ממנו אותה רמת אמינות, observability ו-validation המצופה מכל רכיב תוכנה תפעולי. ארגונים המטמיעים אותו מצפים כיום לא רק לתשובה משכנעת, אלא להתנהגות צפויה, ניתנת לניטור ולחזרה (reproducible). מכאן נובע הצורך במסגרות כמו CrewAI, המגדירות במפורש Agent, Task, Crew ו-Process כדי לתחום אחריות ולאפשר פיקוח. המעבר משכבת עזר לשכבה תפעולית מחייב מהנדסים לתפוס את ה-Agent לא כקסם גנרטיבי, אלא כרכיב מערכת מתוזמר בעל קלט מוגדר, פלט מאומת והקשר (Context) מבוקר. זוהי המהפכה שהפרק הזה בא לתאר ולבסס.

1.2 מדוע prompt בודד וארוך נכשל

הפיתוי הראשוני בבניית מערכת מבוססת מודל שפה הוא לדחוס את כל הדרישות ל-prompt בודד וארוך: להסביר את המשימה, לצרף את כל הנתונים, לפרט את הכללים ולקוות שהמודל יפיק תוצאה שלמה במכה אחת. בפועל גישה זו קורסת ככל שמורכבות המשימה גדלה. ראשית, חסר planning: המודל מתבקש להחזיק בו-זמנית את התכנון, הביצוע והבדיקה, ולכן נוטה לדלג על שלבים או לסתור את עצמו. שנית, חסר memory:

בלא מנגנון זיכרון מפורש כל אינטראקציה מתחילה מאפס, ומידע שנצבר בצעד קודם נשמט. שלישית, חסרים tools: מודל מבודד אינו יכול לקרוא קובץ עדכני, להריץ חישוב מדויק או לפנות ל-API חיצוני, ולכן הוא ממציא עובדות במקום לאחזר אותן. ומעל הכל חסרה שכבת בקרה, ה-Harness, שתפקידה לתזמר את הצעדים, לאכוף סכמות, להפעיל validation על כל פלט ולמנוע משגיאה בצעד אחד לזהם את כל התהליך. ה-Harness הוא שהופך אוסף קריאות למודל למערכת תפעולית אמינה: הוא קובע סדר, מטפל בכשלים, מספק observability ומאפשר חזרתיות. לפיכך prompt בודד אינו נכשל בשל חולשת המודל, אלא בשל היעדר ארכיטקטורה סביבו. המסקנה היא שמערכת סוכנים רצינית דורשת הפרדה מפורשת בין תכנון, זיכרון, כלים ובקרה.

1.3 תזת הספר: פירוק לצעדים תחומים, ניתנים לבדיקה ולשליטה

התזה המרכזית של ספר זה היא שכדי להפוך משימה גנרטיבית רחבה למערכת אמינה יש לפרק אותה לצעדים תחומים (bounded), ניתנים לבדיקה (inspectable) וניתנים לשליטה (controllable). במקום לבקש מן המודל להפיק תוצר ענק במכה אחת, אנו מגדירים שרשרת של Task יחידות, שלכל אחת קלט מוגדר, פלט בעל סכמה ברורה ואחריות מצומצמת. צעד תחום פירושו שהיקפו ידוע מראש ושאפשר להעריך את הצלחתו במנותק מן השאר. צעד ניתן לבדיקה פירושו שהפלט שלו אינו קופסה שחורה אלא artifact שאפשר לפתוח, לאמת מול validation ולהשוות לציפייה, כך ש-observability נבנית לתוך המערכת ולא מודבקת עליה בדיעבד. צעד ניתן לשליטה פירושו שה-Harness יכול לעצור, לחזור על צעד, להחליף Context או לחסום פלט שאינו עומד בכללים, בטרם יזרום הלאה. כך, למשל, הפקת מסמך LaTeX מורכב הופכת לרצף של צעדים, שכל אחד מהם מיוצר ונבדק בנפרד, במקום ניסיון יחיד ושביר. גישה זו ממירה את אי-הוודאות הגנרטיבית במבנה הנדסי: ה-Agent עדיין מספק את היצירתיות, ואילו ה-Process וה-Crew מספקים את המשמעת. שאר הספר מפתח עיקרון זה לכדי דפוסי תכן מעשיים, ומראה כיצד בונים מערכות סוכנים שניתן לסמוך עליהן בסביבה תפעולית אמיתית. לקריאה נוספת בנושאי פרק זה, ראו [1].

1.4 איורים, טבלה ונוסחה

פרק זה מסתמך על תיעוד ה-[1] framework.

$$Q = \sum_{i=1}^n w_i \cdot s_i \quad (1.1)$$

1.5 מעבר דו-כיווני בין עברית לאנגלית

הטקסט הראשי כתוב בעברית (RTL), ומונחים טכניים נשמרים באנגלית (LTR). לדוגמה, משפט שלם באנגלית: The system combines planning, research, writing, and

AI Agent Orchestration

איור 1.1: המחשה רעיונית של תזמור סוכנים (agent orchestration).

BookGen Sequential Agent and Harness Pipeline



איור 1.2: צינור סוכנים סדרתי עם Harness דטרמיניסטי.

review under a deterministic harness. כאן מודגם המעבר התקין בין כיוון הכתיבה מימין-לשמאל לכיוון משמאל-לימין.

תחום אחריות	Agent
תכנון מבנה המסמך	Planner
מחקר מותאם למקורות	Research
כתיבת כתב היד	Writer
ביקורת עריכה	Reviewer
מפרט הרכבה ל-LaTeX	LaTeX

טבלה 1.1: תחומי האחריות של כל Agent ורכיב דטרמיניסטי.

פרק 2

אבני הבניין של CrewAI

2.1 Agent: עובד דיגיטלי בעל תפקיד

ב-CrewAI ה-Agent אינו עוד קריאה גולמית למודל שפה, אלא ישות מובנית המגלמת עובד דיגיטלי בעל זהות ברורה. כל Agent מוגדר באמצעות שלושה רכיבים מרכזיים המעצבים את התנהגותו: role, המתאר את התפקיד המקצועי שהוא ממלא, למשל חוקר, מהנדס תוכנה או עורך לשוני; goal, המנסח את המטרה הקונקרטית שאליה הוא חותר; ו-backstory, המספק רקע ונקודת מבט ומעניק לו אישיות, סגנון והקשר התנהגותי. צירוף שלושת הרכיבים אינו קישוט ספרותי בלבד, אלא מנגנון מעשי המעצב את ה-prompt הפנימי, ממקד את היגיון המודל ומפחית סטייה מן המשימה. מעבר להגדרה הטקסטואלית, ל-Agent מוצמדים tools – כלים חיצוניים כגון חיפוש ברשת, קריאת קבצים, הרצת קוד או פנייה ל-API – המרחיבים את יכולותיו אל מעבר לטקסט שהמודל מסוגל לייצר מתוך עצמו. כך ה-Agent הופך לישות הפועלת בעולם, ולא רק מדברת עליו. ההבחנה בין Agent לבין model call פשוטה אך עקרונית: model call הוא אירוע חד-פעמי וחסר זיכרון, ואילו ה-Agent הוא יחידה בעלת תפקיד מתמשך, יכולות מוגדרות ואחריות ברורה בתוך ה-Crew. תפיסה זו מאפשרת לפרק מערכת מורכבת לעובדים מתמחים, שכל אחד מהם אחראי לתחום צר ומוגדר, ובכך לשפר את המודולריות, השקיפות ויכולת התחזוקה של הפתרון כולו.

2.2 Task: יחידת עבודה מדידה

ה-Task הוא יחידת העבודה האטומית של CrewAI, והוא מתרגם כוונה כללית למשימה קונקרטית, מוגדרת ומדידה. כל Task נשען על שני רכיבים שאי אפשר לוותר עליהם: description, המתאר במדויק מה צריך להיעשות ואילו שיקולים יש לקחת בחשבון, ו-expected output, המגדיר במפורש כיצד נראית תוצאה ראויה ומה צורתה הצפויה. ההגדרה המפורשת של ה-expected output היא לב העניין, משום שהיא הופכת את המשימה מעמומה לכזו שניתן לאמת מולה באמצעות validation. כאשר התוצר הצפוי

הוא, למשל, טבלה בפורמט מסוים, קובץ LaTeX תקין או רשימת ממצאים מובנית, ה-Crew יכול לבדוק אם הפלט עומד בציפייה, במקום להסתפק בהתרשמות סובייקטיבית. כל Task משויך בדרך כלל ל-Agent מסוים האחראי לביצועו, וכך נוצר חיבור ישיר בין התפקיד לבין העבודה המבוצעת בפועל. ה-Task יכול גם לקבל Context מ-tasks שקדמו לו ולהזין את אלה שיבואו אחריו, וכך הוא הופך לחוליה בשרשרת ולא לאי מבודד. הגדרת העבודה כיחידות מדידות תומכת ישירות ב-observability: כל שלב ניתן למעקב, לרישום ולבחינה, וכשל מקומי ניתן לאיתור ולתיקון בלי לפרק את המערכת כולה. כך CrewAI מאפשר לבנות תהליכים אמנים, שבהם ההצלחה אינה עניין של מזל אלא תוצאה של דרישות ברורות וקריטריונים שניתן למדוד מולם בכל ריצה.

2.3 Crew, Process ו-Context: הרכבה ודבק

לאחר שהוגדרו ה-Agents וה-Tasks, נדרש מנגנון שירכיב אותם למערכת פועלת אחת, וכאן נכנסים לתמונה ה-Crew, ה-Process וה-Context. ה-Crew הוא המעטפת המאגדת קבוצת Agents ואת ה-Tasks המוטלים עליהם ליחידת עבודה אחת בעלת מטרה משותפת, בדומה לצוות אנושי שכל חבר בו תורם את התמחותו. ה-Process מגדיר כיצד הצוות מופעל: ב-Process מסוג sequential ה-Tasks מתבצעים בזה אחר זה לפי סדר קבוע, ואילו ב-Process מסוג hierarchical מתמנה מנהל המחלק ומתאם את העבודה בין החברים. בחירת ה-Process קובעת את אופי התיאום ואת זרימת השליטה בין השלבים. הרכיב המאחד את הכול הוא ה-Context, המשמש דבק בין השלבים. ה-Context הוא המידע העובר משלב לשלב: תוצר של Task אחד הופך לקלט או לרקע של ה-Task הבא, כך שכל שלב נבנה על גבי מה שקדם לו ולא מתחיל מאפס. בלי Context היה הצוות אוסף של עובדים מנותקים שאינם מודעים זה לעבודתו של זה; עם Context נוצרת שרשרת קוהרנטית שבה הידע מצטבר וזורם. כך הרכבת ה-Agents וה-Tasks בתוך Crew, יחד עם Process מתאים ו-Context רציף, היא שמאפשרת ל-CrewAI להפוך רכיבים בודדים ל-orchestration של ממש, שבו השלם גדול מסכום חלקיו ומסוגל לבצע משימות מורכבות מקצה לקצה.

לקריאה נוספת בנושאי פרק זה, ראו [2].

פרק 3

תזמור סדרתי הלכה למעשה Sequential Orchestration in) (Practice

3.1 מדוע Sequential Process מתאים להפקת מסמכים

הפקת מסמך עיון מקצועי אינה פעולה בודדת אלא רצף שלבים שבו כל שלב נשען על תוצר השלב שקדם לו, ולכן Sequential Process ב-CrewAI הוא הבחירה הטבעית עבורה. אי אפשר לחקור נושא לפני שקיים book plan הממקד את החקירה, אי אפשר לכתוב manuscript לפני שה-research pack מספק את החומר, אי אפשר לבצע review לפני שקיים draft, ואי אפשר לבנות latex spec לפני שהתוכן עבר ביקורת והתייצב. תלות חד-כיוונית זו היא בדיוק מה ש-Sequential Process מבטא: ה-Crew מריץ Task אחר Task בסדר קבוע, וה-Context של כל Task מורכב מתוצרי ה-Tasks שקדמו לו. היתרון המעשי הוא שהזרימה גלויה וניתנת לבדיקה, שכן בכל נקודה ברור איזה artifact כבר קיים ומהי הכניסה הצפויה לשלב הבא. בניגוד ל-hierarchical process, שבו Manager Agent מנתב עבודה באופן דינמי, ה-Sequential Process פשוט יותר להסבר, צפוי יותר בהתנהגותו, וקל יותר ל-observability ול-validation. בפרויקט זה הוא גם מבטא עיקרון הנדסי חשוב: עבודה דטרמיניסטית כמו citation management, יצירת assets, רינדור LaTeX והידור PDF נשארת מחוץ ל-Crew ורצה ב-Harness לאחר חמשת ה-Agent Tasks. כך נוצר גבול ברור בין שיקול דעת של מודל לבין צעדים ניתנים לאימות, וכל סטייה מהסדר הצפוי נחשפת מיד.

3.2 חמשת ה-Agents המתמחים ותפקידיהם

המערכת מורכבת מחמישה Agents, שכל אחד מהם מוגדר באמצעות role, goal ו-backstory, ובאופן מכוון תחומי האחריות שלהם אינם חופפים. ה-Planner Agent מתפקד

כעורך טכני בכיר: הוא ממיר את הנושא ואת דרישות המטלה ל-book plan הכולל מבנה פרקים, מיקום של image, graph, table ו-formula, ו-acceptance checklist, אך אינו כותב פרוזה. ה-Research Agent הוא אנליסט מחקר האוסף מושגי מפתח, הגדרות ומועמדים למקורות, ורק לו מותר להשתמש בכלי חיפוש חיצוניים; הוא מציע source candidates אך אינו מייצר את ה-bibliography הסופי. ה-Writer Agent הוא כותב טכני בכיר העובד מתוך ה-Context בלבד, ללא חיפוש עצמאי, וממיר את התוכנית ואת המחקר ל-manuscript עם citation markers ו-placeholders. ה-Reviewer Agent הוא עורך ובוחן דרישות: הוא משפר בהירות ודיוק מבלי לשנות את המשמעות, ומפיק review report הכולל requirement checklist ואזהרות. ה-LaTeX Agent מתכנן את ה-assembly ומפיק latex spec, אך אינו מריץ קומפילר ואינו אחראי ל-build correctness. הפרדה חדה זו, המעוגנת בסעיפי Not Responsible For עבור כל Agent, מונעת התנגשות תפקידים, שומרת על מערכת קטנה הניתנת להסבר, ומבטיחה שכל החלטה תיפול במקום אחד ויחיד בשרשרת. כך כל Agent נושא באחריות צרה וברורה, ושיתוף הפעולה ביניהם נשען על ממשק מוגדר ולא על חפיפה מקרית.

3.3 העברת artifacts מובנים כ-Context לאורך השרשרת

הדבק המחבר את חמשת ה-Context Tasks הוא ה-Context: כל Agent שלאחר ה-Planner צורך במפורש את תוצרי השלבים שקדמו לו, וההעברה נעשית באמצעות artifacts מובנים ולא כטקסט חופשי. ה-Planner מפיק את ה-book plan, המשמש Context ל-Research Task; ה-Research Agent מפיק את ה-research pack, וזה יחד עם ה-book plan מהווה את ה-Context של ה-Writing Task; ה-Writer מפיק את ה-manuscript; ה-Reviewer מקבל את שלושת התוצרים יחד ומחזיר reviewed manuscript ו-review report; ולבסוף ה-LaTeX Agent צורך את ה-book plan, את ה-reviewed manuscript ואת ה-review report כדי לבנות את ה-latex spec. שרשרת מצטברת זו מבטיחה שהחלטות מוקדמות, כמו ה-acceptance checklist של ה-Planner, נשארות זמינות ונבדקות עד סוף הזרימה. הבחירה ב-artifacts מובנים, רובם בפורמט JSON עם expected output מוגדר לכל Task, היא שמאפשרת validation דטרמיניסטי לאחר שה-Crew מסיים: ה-Harness יכול לוודא שכל citation marker מתאים למקור מוכר, שה-latex spec מפנה לקבצים תקפים, ושכל דרישת המטלה מכוסה. כך ה-Context אינו רק מנגנון תקשורת בין Agents אלא גם שכבת חוזה הניתנת לאכיפה, ההופכת את ה-Sequential Orchestration למערכת שקופה, ניתנת למעקב וניתנת לאימות מקצה לקצה.

לקריאה נוספת בנושאי פרק זה, ראו [3].

פרק 4

The Deterministic Harness – תשתית דטרמיניסטית סביב הסקת המודל

4.1 מהו Harness ולמה הוא דטרמיניסטי

בלב הארכיטקטורה שלנו עומד רעיון פשוט אך מכריע: את הסקת המודל יש לעטוף בשכבת תוכנה דטרמיניסטית הקרויה Harness. מודל שפה הוא רכיב הסתברותי מטבעו – בהינתן אותו prompt הוא עשוי להחזיר פלטים שונים, להמציא תחביר או לחרוג מהמבנה הצפוי. לכן אנו מפרידים בחדות בין שתי שכבות אחריות. ה-Agents של CrewAI – Planner, Research, Writer, Reviewer – ו-LaTeX – מבצעים את העבודה האינטלקטואלית הדורשת judgment: תכנון, סינתזה של מחקר, כתיבת פרוזה ועריכה. ה-Harness, לעומתם, מבצע את העבודה השבירה והניתנת לאימות באמצעות קוד Python קבוע: reconciliation של ציטוטים, יצירת graph, validation, escaping של תווים ו-compilation של ה-PDF. ההשראה לכך מגיעה מתפיסת ה-production harness, שבה Harness אמיתי עוטף את קריאות המודל ב-tools, ב-context, ב-parsing, ב-validation, ב-observability וב-guardrails. ההיגיון הוא שכל פעולה שתוצאתה חייבת להיות נכונה ובת-שחזור אסור שתישען על אלתור של מודל. כך פלט ה-Agent נשמר כ-artifact מובנה ובר-בדיקה – למשל book_plan או manuscript – וה-Harness צורך אותו, מאמת אותו וממיר אותו לתוצר סופי. תכן זה ממקם את אי-הוודאות במקום אחד ומבוקר: בתוך הסקת המודל בלבד. כל מה שמסביב הופך לצינור הנדסי צפוי, שניתן להריץ שוב ושוב ולקבל בכל פעם בדיוק אותה התנהגות, וכך מערכת יצירתית במהותה הופכת למערכת אמינה תפעולית.

4.2 ציטוטים, graph ו-validation כרכיבים דטרמיניסטיים

שלוש משימות בולטות מודגמות במערכת כרכיבים דטרמיניסטיים מובהקים – ולא כ-Agents. הראשונה היא ניהול הציטוטים. אסור שמודל ימציא רשומות bibliography או citation keys, ולכן ה-Citation Manager הוא קוד Python: הוא קורא source registry

אצור ומבוקר, מייצר קובץ references.bib תקין תחבירית עם escaping בטוח, ומבצע reconciliation המוודא שכל citation marker ב-manuscript נפתר למקור מוכר. אם מופיע מפתח שאינו מזוהה, התהליך נכשל בקול רם עוד לפני ה-compilation, ועיקרון מפתח כאן הוא idempotency: אותו registry מפיק תמיד בדיוק אותו .bib. המשימה השנייה היא יצירת ה-graph. השרטוט המתאר את ה-Planner — pipeline אל Research אל Writer אל Reviewer אל LaTeX ואל רכיבי הבנייה הדטרמיניסטיים — נוצר בקוד Python קבוע ולא על ידי Agent, שכן graph דטרמיניסטי הוא בר-שחזור וקל ל-validation. המשימה השלישית היא ה-validation עצמה. ה-Validator הדטרמיניסטי מוודא שכל הרכיבים הנדרשים קיימים לפני ה-compilation: cover metadata, TOC, chapters, sections, לפחות תמונה אחת, קובץ ה-graph, table, נוסחת display שאינה טקסט רגיל, מקטע BiDi עברית-אנגלית, citation keys תקפים וקובצי ה-LaTeX source. חלוקה זו עקבית עם תפיסת הקורס: עבודה השופטת איכות ומשמעות נשארת אצל Agent כמו ה-Reviewer, אך הבדיקה הטכנית — האם הכול מחובר, מתקמפל ותקין — חייבת להיות דטרמיניסטית, שכן זו בדיקה הנדסית הניתנת ל-testing אובייקטיבי ולא שיפוט תוכן.

4.3 דטרמיניזם, reproducibility ופלט אמין

הדטרמיניזם אינו קישוט הנדסי אלא תנאי יסוד לשלושה ערכים שבלעדיהם המערכת אינה ראויה לאמון. הראשון הוא reproducibility. כאשר רכיבי ה-Harness מתנהגים באופן צפוי, הרצה חוזרת על אותם artifacts מפיקה בדיוק את אותו פלט — אותו references.bib, אותו graph ואותו validation report. תכונה זו חיונית במיוחד בתוצר אקדמי מדורג, שבו בודק חייב להיות מסוגל לשחזר את הבנייה ולקבל את אותו final.pdf. הערך השני הוא testing. רכיב הסתברותי קשה לבדיקה, שכן אין לו פלט יחיד נכון; רכיב דטרמיניסטי, לעומתו, ניתן לכסות ב-unit tests מדויקים: לוודא ש-citation key שאינו מזוהה מדווח כ-unresolved, שתווים מיוחדים עוברים escaping, ושאותו registry מפיק שוב את אותו .bib. כך ה-schema validation, citation validation, asset validation, quality gates ו-LaTeX validation — הופכים לבדיקות אוטומטיות אמיןות במקום הסתמכות על שיפוט אנושי. הערך השלישי הוא trustworthy output. בכך שאנו ממקמים את אי-הוודאות אך ורק בתוך הסקת המודל ועוטפים אותה ב-validation וב-guardrails, אנו מבטיחים שתקלה של Agent — מפתח שגוי, נכס חסר או נוסחה פגומה — נתפסת מוקדם ובאופן גלוי, ואינה מתפשטת בשקט אל המסמך הסופי. שילוב היצירתיות ההסתברותית של המודל עם תשתית דטרמיניסטית קפדנית הוא שמאפשר למערכת להיות בו-זמנית גמישה בתוכן ואמינה בתוצר, וזהו בדיוק האיזון שתזמור סוכנים מקצועי שואף אליו. לקריאה נוספת בנושאי פרק זה, ראו [1].

פרק 5

הפקת מסמכים מקצועיים באמצעות LaTeX

5.1 מ-artifacts מאומתים ל-LaTeX: templates ו-escaping

לאחר שכל ה-Agents סיימו את עבודתם ושלב ה-validation אישר את התוצרים, עומד לרשותנו אוסף של artifacts מובנים: כתב היד שעבר review, מטא-נתונים, נכסים גרפיים וקובץ מקורות. השלב הבא אינו שלב יצירתי אלא דטרמיניסטי לחלוטין, ובכך טמון עיקרון מרכזי בתכנון המערכת. ה-Agent מתאר כוונה בלבד, באמצעות מסמך latex_spec מובנה הקובע איזה template לבחור, כיצד למפות פרקים וכיצד לשבץ נכסים, אך לעולם אינו כותב LaTeX גולמי בעצמו. את הרינדור מבצע רכיב Python ייעודי, ה-renderer, הממלא templates של Jinja2 בתוכן המאומת ומפיק את הקובץ main.tex ואת קבצי הפרקים. הפרדה זו בין שיקול הדעת של ה-Agent לבין ההפקה הדטרמיניסטית היא לב ההבטחה לשחזוריות (reproducibility). אתגר קריטי בשלב זה הוא escaping: טקסט שמקורו ב-Agent נחשב untrusted text, ותווים מיוחדים של LaTeX, כדוגמת סימני אחוז, אמפרסנד או סוגריים מסולסלים, עלולים לשבור את הקומפילציה ואף לאפשר הזרקת פקודות. לכן ה-renderer מחזיק מודול escaping ייעודי, המעבד כל מחרוזת לפני שיבוצה ב-template ומבטיח שתוכן שרירותי לא יהפוך לקוד פעיל. כך מתקבל קוד מקור תקני, אחיד וצפוי, שאינו תלוי בגחמות הניסוח של המודל. גישה זו תומכת גם ב-observability: מאחר שה-renderer ידוע ומבוקר, ניתן להריץ אותו אף ללא toolchain מותקן ולקבל קובצי tex תקפים לבדיקה. כך מופרד בבירור שלב ההרכבה משלב הקומפילציה בפועל, וכל סטייה בתוכן נחשפת עוד לפני ההידור.

5.2 כתיבה דו-כיוונית עברית-אנגלית עם מנוע Unicode

מסמך מקצועי בעברית המשלב מונחים טכניים באנגלית מציב אתגר טיפוגרפי של ממש, שכן עברית נכתבת מימין לשמאל ואילו מונחים כדוגמת Agent, Crew או validation

נכתבים משמאל לימין באותה שורה. ניהול נכון של מצב זה, המכונה BiDi או bidirectional typesetting, מחייב מנוע מודרני המבוסס על Unicode. מנוע pdfLaTeX הוותיק אינו מספק תמיכה אמינה בכך, ולכן המערכת בוחרת ב-LuaLaTeX כברירת מחדל, עם XeLaTeX כ-fallback. שני מנועים אלה קוראים ישירות קבצים בקידוד Unicode ויודעים לטעון גופנים מודרניים התומכים בעברית, וכך מתייתרות שכבות הקידוד המסורבלות של העבר. את ניהול השפות מבצעת חבילת polyglossia יחד עם רכיב bidi, המחליפים את החבילות הישנות שלא הותאמו לעברית. polyglossia מאפשרת להגדיר שפה ראשית ושפה משנית ולעבור ביניהן באופן מפורש, כך שכל קטע טקסט מקבל את כיוון הכתיבה הנכון לו. העיקרון המעשי הוא בידוד: יש לעטוף כל רצף באנגלית בתוך משפט עברי כך שיישמר כיחידה רציפה משמאל לימין, ולמנוע מהאלגוריתם הדו-כיווני לערבב את סדר האותיות סביב נקודות המעבר. בקרת איכות מחייבת אימות חזותי של המעברים: יש לוודא שמספרים, סימני פיסוק וסוגריים נצמדים לצד הנכון, ושמונחים טכניים אינם נשברים. ה-renderer מקבל מטא-נתוני BiDi מתוך ה-latex_spec ומשבץ את מתגי השפה במקומותיהם הנכונים, כך שגם תוצר רב-לשוני זה נשאר דטרמיניסטי וניתן לשחזר מלא.

5.3 ביבליוגרפיה וקומפילציה רב-מעברית של citations

אחד ההיבטים הפחות אינטואיטיביים בהפקת מסמך LaTeX הוא שאי אפשר להפיק ביבליוגרפיה תקינה במעבר קומפילציה יחיד. הסיבה נעוצה באופן שבו LaTeX פותר הפניות: במעבר הראשון המהדר אינו יודע עדיין לאילו מקורות מפנה הטקסט, ולכן הוא רק אוסף את סימני ה-citation ורושם אותם בקובצי עזר, כדוגמת קובץ aux וקובץ bcf. רק לאחר מכן נכנס לפעולה ה-backend הביבליוגרפי, biber, הקורא את רשימת ההפניות שנאספה, מצליב אותה מול קובץ references.bib, וממין ומעצב את הרשומות לפי סגנון הציטוט הנדרש. המעברים הבאים של המהדר משלבים פלט זה חזרה אל המסמך, וממלאים את מספרי ההפניות ואת רשימת המקורות במקומותיהם. לכן הרצף הקנוני במערכת הוא ריצת המהדר, אחריה biber, ואחריה שתי ריצות נוספות של המהדר. ללא רצף זה יישארו במסמך סימני שאלה כפולים במקום מספרי citation, וגם cross-references פנימיים, כדוגמת הפניות לאיורים ולטבלאות, לא יפתרו. כאן בולט שוב עקרון ההפרדה: ניהול ה-citations עצמו דטרמיניסטי ואינו Agent, שכן אסור שמודל ימציא מפתחות או רשומות. קובץ ה-bib נוצר מתוך רישום מקורות מבוקר, ושלב reconciliation מאמת שכל citation marker במסמך מתאים למקור מוכר, ונכשל בקול רם אם נמצא מפתח שאינו קיים. כך משלבת המערכת קומפילציה רב-מעברית עם validation מחמיר, ומבטיחה מסמך אקדמי אמין שבו כל הפניה נפתרת כראוי. לקריאה נוספת בנושאי פרק זה, ראו [2].

פרק 6

מהוכחת היתכנות לסביבת Production

6.1 הפער השקט בין Demo ל-Production

ההבדל בין Demo מרשים למערכת Production אינו נמדד באיכות פלט בודד, אלא בהתנהגות המערכת תחת שינוי, כשל ועומס. ב-Demo כל Agent מקבל קלט נקי, ה-Crew מריץ Process יחיד בנתיב מאושר מראש, וה-Context עובר בין השלבים בדיוק כמצופה. ברגע שמערכת התזמור פוגשת קלטים אמיתיים נחשף הפער השקט שאיש אינו רואה במצגת: מה קורה כש-Task נכשל באמצע השרשרת, כשמודל מחזיר LaTeX שבור או JSON שאינו עובר validation, או כששירות חיצוני קורס. מערכת Production מחייבת recovery מובנה – ניסיון חוזר עם backoff, נתיב fallback, ומנגנון שמבודד כשל של Agent בודד כדי שלא יפיל את ה-Crew כולו. לצד ההתאוששות נדרשת monitoring רציפה: לא לוג יחיד בסוף הריצה, אלא observability בכל שלב, עם מדדי זמן, שיעורי כשל, ועקיבות מלאה אחר ה-Context העובר בין ה-Tasks. שכבת ה-Harness הדטרמיניסטית קריטית כאן, משום שהיא מאפשרת לשחזר ריצה, להשוות פלטים, ולזהות רגרסיה כשמודל או prompt משתנים. בלי control מפורש על השינוי – גרסאות נעולות של מודלים, בדיקות שמריצות תרחישים מוכרים לפני פריסה, ושערי validation החוסמים פלט לא תקין – המערכת תתפקד היטב היום ותיכשל באופן בלתי צפוי מחר. המעבר ל-Production הוא במידה רבה מעבר מאופטימיזציה למקרה הטוב לעיצוב למקרה הגרוע, שבו כל רכיב מתוכנן מראש להיכשל בחן ולהתאושש באופן נשלט.

6.2 אבטחת Agents ומודעות לעלות

כשמערכת תזמור עוברת ל-Production, כל Agent הופך הן למשטח תקיפה פוטנציאלי והן למקור הוצאה כספית, ושני הממדים הללו דורשים משמעת הנדסית. עקרון ה-least privilege הוא הבסיס: כל Agent מקבל אך ורק את הכלים, ההרשאות והגישה לנתונים הדרושים למשימתו, ולא יותר מכך. Agent שתפקידו לעצב LaTeX אינו זקוק לגישה לרשת או למפתחות API חיצוניים, ו-Agent שמסכם נתונים אינו צריך הרשאת כתיבה למאגר.

הפרדה זו מצמצמת את הנזק כאשר prompt injection או קלט עוין מצליחים לחדור. מעליה נדרשים guardrails – שכבות validation הבודקות הן את הקלט הנכנס והן את הפלט היוצא, מסננות הוראות זדוניות המוטמעות ב-Context, ומוודאות שהפעולות שה-Agent מבקש לבצע נמצאות בתחום המותר. במקביל, מודעות לעלות אינה מותרות אלא חלק מהארכיטקטורה: כל קריאה למודל צורכת tokens שעולים כסף, ושרשרת Tasks ארוכה עם Context נפוח עלולה לייקר ריצה בודדת פי כמה. משמעת של token-cost מחייבת מדידה לכל Task, תקצוב מרבי לריצה, בחירה מושכלת בין מודל יקר וחזק למודל זול וקל למשימות פשוטות, וצמצום ה-Context המועבר לרלוונטי בלבד. ניטור עלות לצד observability מאפשר לזהות Agent שנכנס ללולאה יקרה או prompt שמנפח צריכה. אבטחה ועלות הם שני צדדים של אותה משמעת: שליטה הדוקה במה שכל Agent רשאי לעשות ובמה שכל Agent מבזבז.

6.3 מחסנית מודולרית והכיוון הבא

מערכת Production בוגרת נשענת על מחסנית מודולרית ומנוטרת, שבה כל רכיב – הגדרת Agent, Task, בחירת Process, שכבת ה-Harness ושערי ה-validation – ניתן להחלפה, לבדיקה ולניטור בנפרד. מודולריות זו אינה נוחות הנדסית בלבד אלא תנאי להתפתחות: כשהגבולות בין הרכיבים ברורים ו-observability מכסה כל שלב, ניתן לשדרג רכיב אחד מבלי לסכן את השלם, ולהריץ ניסויים מבוקרים. מנקודה זו הארכיטקטורה ממשיכה בכמה כיוונים טבעיים. הראשון הוא hierarchical crews – במקום Crew שטוח שבו כל Agent שווה, נוצר Agent מנהל המתזמר Agents כפופים, מפרק בעיה מורכבת לתת-משימות, ומקצה אותן באופן דינמי. מבנה היררכי כזה מאפשר להתמודד עם משימות פתוחות שאינן ניתנות לתכנון מראש ב-Process קווי. הכיוון השני הוא שילוב RAG, שבו ה-Agents שואבים ידע עדכני ומבוסס ממאגר חיצוני במקום להישען על משקלי המודל בלבד, וכך משפרים דיוק ומצמצמים hallucination בתחומי ידע ספציפיים. הכיוון השלישי, ואולי החשוב מכולם לאורך זמן, הוא evaluation שיטתי: מסגרת מדידה שמריצה את ה-Crew על אוסף תרחישים מייצגים, מציינת את איכות הפלטים מול קריטריונים מוגדרים, ומזהה גרסיה לפני פריסה. בלי evaluation אובייקטיבי כל שיפור נותר ניחוש. שילוב של מחסנית מודולרית, RAG, hierarchical crews ו-evaluation הוא הנתיב שבו מערכת תזמור הופכת מכלי חד-פעמי לפלטפורמה המתפתחת, נמדדת ומשתפרת באופן שיטתי. לקריאה נוספת בנושאי פרק זה, ראו [3].

ביבליוגרפיה

- CrewAI. CrewAI Documentation. Framework documentation for CrewAI agents, [1]
tasks, crews, and processes. 2026. URL
<https://docs.crewai.com/>
- LangChain. LangChain Documentation. Reference material for harness-style LLM [2]
application design. 2026. URL
<https://python.langchain.com/>
- The LaTeX Project. LaTeX Project Documentation. Reference documentation for [3]
professional LaTeX document preparation. 2026. URL
<https://www.latex-project.org/help/documentation/>